

Лето с AIRI 20.08.2024-30.08.2024

Отчет о выполнении проекта

№4: Is attention all you need? - CNN+attention for spatio temporal data

Борисова Юлия, Кошкина Василиса

Цель проекта: Разработка и тестирование различных моделей глубокого обучения для долгосрочного прогнозирования концентрации морского льда

Задачи проекта:

1. Реализация сверточной сети без/с механизмом внимания.
2. Реализация модели, основанной на архитектуре U-Net.
3. Применение разработанных моделей на наборе данных о концентрации льда.
4. Оценка качества результатов и определение применимости методов.

1. Введение

Моделирование льда в российской Арктике с использованием искусственного интеллекта (ИИ) представляет собой передовой подход к изучению и прогнозированию изменений ледового покрова в этом стратегически важном регионе. В последние годы ИИ стал незаменимым инструментом для ученых и исследователей, работающих в области климатологии и арктических исследований.

Качественное прогнозирование ледовой обстановки важно для ряда сфер:

- Навигация: Точные прогнозы ледовой обстановки помогают судам безопасно проходить через арктические воды, снижая риск аварий и экономические затраты.
- Экологический мониторинг: Моделирование льда помогает отслеживать изменения в экосистемах Арктики и оценивать влияние климатических изменений на флору и фауну.
- Научные исследования: Результаты моделирования используются для углубленного изучения климатических процессов и разработки стратегий адаптации к изменяющемуся климату.

Накопление спутниковых данных позволило эффективно перейти от тяжеловесных моделей на основе систем дифференциальных уравнений к data-driven моделям, обучающимся на массивах исторических данных.

В данной работе мы ставим задачу долгосрочного прогнозирования ледовой обстановки (с заблаговременностью прогноза 1 год), так как по сравнению с краткосрочным прогнозированием на месяцы и дни она является менее освещенной в литературе и нуждается в повышении качества за счет использования новых подходов к моделированию.

2. Постановка задачи

В качестве данных для обучения был выбран продукт [OSISAF](#) (Ocean and Sea Ice Satellite Application Facility) за весь доступный период 1979-2024 годы. В качестве прогнозируемого параметра выбрана концентрация льда (изменяется от 0 до 1). Пространственное разрешение данных приведено к 14 км. Дискретность данных была

снижена с суточной до 7-дневной в силу слабой суточной динамики параметра и незначительности изменений для долгосрочного прогноза.

Предполагается разработка модели, способной предсказывать ледовую обстановку на год вперед, используя данные за предыдущие два года. Модель должна уметь:

- Принимать на вход 104 снимка льда (данные за два года).
- Генерировать на выходе 52 снимка льда (данные за один год).

Каждый снимок представляет собой изображение ледового покрова, в виде матрицы значений, где каждый элемент соответствует состоянию льда в определенной точке.

Для реализации экспериментов было осуществлено следующее разбиение всего собранного датасета:

Обучающая выборка:

- Период: 1979-2018 годы.
- Количество снимков: 40 лет данных, что составляет $40 * 52 = 2080$ снимков.

Валидационная выборка:

- Период: 2018-2020 годы.
- Количество снимков: 2 года данных, что составляет $2 * 52 = 104$ снимка.

Тестовая выборка:

- Период: 2020-2024 годы.
- Количество снимков: 4 года данных, что составляет $4 * 52 = 208$ снимков.

Модель обучается на обучающей выборке (1979-2018 годы), валидационная выборка (2018-2020 годы) используется для предотвращения переобучения, оценка модели проводится на тестовой выборке (2020-2024 годы) для проверки ее способности предсказывать ледовую обстановку на год вперед на незнакомых данных.

Для оценки качества модели использовались следующие метрики качества:

- MAE (mean absolute error) - отвечает за соответствие абсолютных значений концентрации льда реальным наблюдениям;
- SSIM (structural similarity index measure) - отвечает за соответствие контуров ледовых кромок на изображении прогноза и реальных наблюдений;
- Ассигасу - бинарная точность в долях единицы соответствия бинаризованных по порогу данных прогноза с бинаризованными реальными наблюдениями. В качестве порога была выбрана концентрация 0.2 так как она используется в исследованиях в качестве маркера наличия льда.

3. Архитектуры нейронных сетей

3.1. Простая сверточная нейронная сеть - CNN

В качестве базовой модели разработана простая сверточная нейронная сеть, которая состоит из 5 слоев двумерной свертки и 5 слоев транспонированной двумерной свертки, между слоями применяется функция активации ReLU, в конце применен

пуллинг (AdaptiveAvgPool2d) для сохранения необходимой размерности на выходе модели. Схема использованной простой свертки представлена на схеме (рисунок 1).

Input: multi-channel image,
prehistory of parameter – n time steps

Output: multi-channel image,
prehistory of parameter – k time steps ahead




Рисунок 1. Схема CNN модели (размерности представлены для входных данных размером 125x125)

К преимуществам разработанной CNN модели относится легкость в обучении за счет простоты архитектуры, а также автоматизированная адаптируемость для произвольных акваторий.

3.2. Модель на основе архитектуры U-Net (resnet-34)

Архитектура U-Net чаще всего применяется в исследованиях для моделирования концентрации льда, не смотря на то, что изначально архитектура разработана для задач классификации и сегментации изображений. В данной работе базовая реализация U-Net взята из библиотеки [Segmentation Models](#). Голова, отвечающая за сегментацию, заменена на дополнительный сверточный слой для сохранения размерностей на выходе из сети. Схема адаптации сети из библиотеки под задачу представлена на рисунке 2.

64x64

resnet-34




Рисунок 2. Схема адаптации архитектуры resnet для задачи прогнозирования льда. Для старта модели было опробовано обучение архитектуры с нуля, а также дообучение с весов, предобученных на датасете imagenet. Графики сходимости для обоих случаев представлены на рисунке 3.

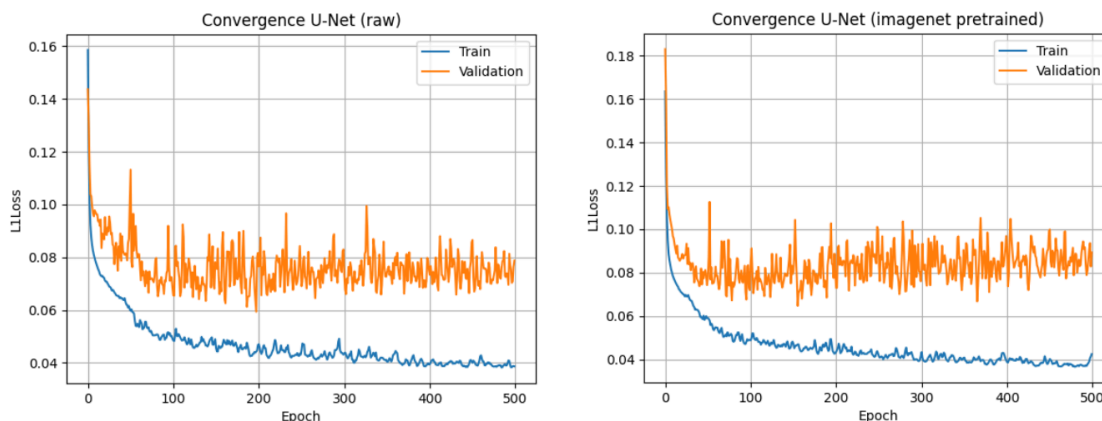


Рисунок 3. Графики сходимости для модели, обучаемой с нуля и модели с предобученными весами

Как видно из графиков, предобученные веса не дают преимущества при обучении, так как медиа изображения из предобученного датасета значительно отличаются по структуре от одноканальных изображений концентрации льда.

3.3. Сверточная сеть с механизмом внимания - *CNN+attention*

Чтобы подтвердить или опровергнуть гипотезу о качественном приросте прогноза сверточной сети с внедрением механизма внимания была реализована адаптация подобной [архитектуры](#), рассчитанной для задач классификации, к задаче прогнозирования льда. Схема финальной архитектуры представлена на рисунке 4.

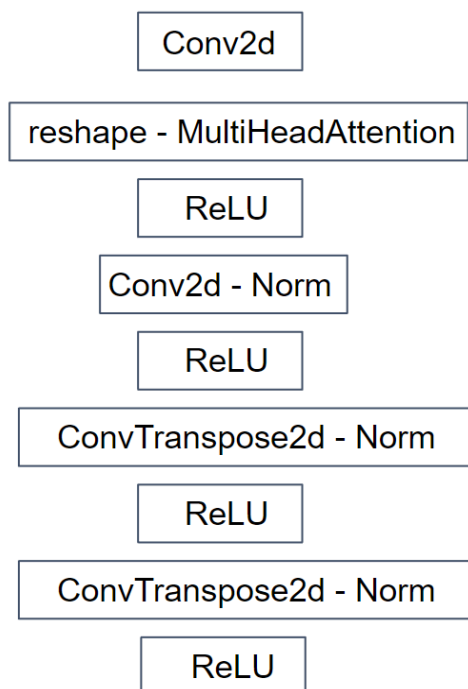


Рисунок 4. Схема CNN+attention модели

4. Результаты моделирования

Для сравнения результатов моделирования, был осуществлен прогноз каждой из моделей. Точка старта прогноза была обозначена 1 января каждого из годов тестовой выборки. На основе результатов предсказания были рассчитаны метрики качества. Ход метрик качества представлен на рисунке 5. Вертикальными линиями отмечены точки старта прогноза.

Стоит отметить что все модели обладают стандартным поведением - качество моделирования снижается в периоды ледостановления (сентябрь - октябрь) и ледотаяния (май-июнь). Для численной оценки качества моделей метрики были усреднены за каждый из годов тестовой выборки. Результаты представлены в таблице 1.




Рисунок 5. Ход метрик качества для предсказания каждой из моделей.

Model	CNN	U-Net	CNN+ attention
MAE			
2020	0,105	0,085	0,095
2021	0,106	0,096	0,080
2022	0,099	0,075	0,093
2023	0,085	0,071	0,081
SSIM			
2020	0,624	0,651	0,643
2021	0,617	0,644	0,653
2022	0,630	0,678	0,647
2023	0,651	0,679	0,656
Accuracy			
2020	0,885	0,912	0,892
2021	0,899	0,908	0,931

Model	CNN	U-Net	CNN+attention
MAE			
2020	0,105	0,085	0,095
2022	0,902	0,931	0,899
2023	0,927	0,941	0,936

Таблица 1. Сравнение среднегодовых метрик качества для каждой из моделей. Как видно из таблицы, U-Net показал лучшее качество по сравнению с другими моделями, что подтверждает обоснованность распространения его использования для задачи прогнозирования льда. Однако в то время как U-Net показал лучшее качество на нестандартных годах, attention CNN превзошел его в воспроизведении типичной динамики.

Карты для даты прогноза с наиболее сильным отличием между моделями представлены на рисунке 6.

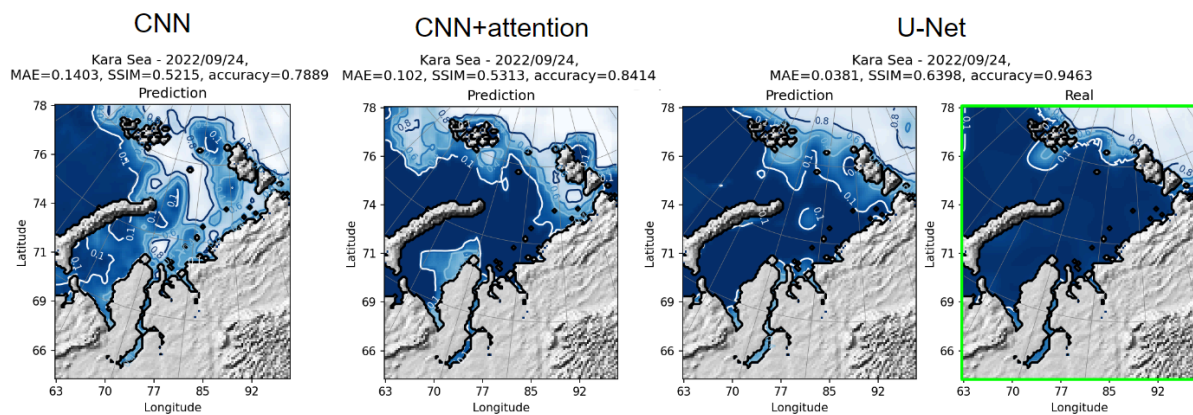


Рисунок 6. Карты прогноза ледовых условий для периода ледостановления 2022 года. Как видно из рисунка 6, U-Net наиболее точно воспроизвел запоздание ледовой фазы (лед в 2022 году начал замерзать позже).

5. Заключение

Таким образом в результате проделанных экспериментов можно очертить применимость реализованных методов:

- U-Net показал лучшее качество на нестандартных годах;
- attention CNN показал лучшее качество прогноза на типичной динамике концентрации льда;
- Простая сверточная сеть слабо адаптируется к нестандартным условиям, отсутствующим в обучающей выборке и дает худшее качество предсказания.

Выводы:

- U-Net показал лучшее качество по сравнению с моделью с механизмом внимания, что подтверждает негласный статус U-Net как базовой модели для прогнозирования ледовой обстановки;

- Добавление в архитектуру U-Net механизма внимания может повысить качество для прогнозирования типичной динамики ледовых условий;
- Протестированные архитектуры все еще требуют параметризации для каждой акватории, генерализуемость подхода нуждается в доработке.

Дальнейшие планы:

- Эксперименты с архитектурой;
- Усвоение дополнительных предикторов - информации о сезоне, потоке приходящей солнечной радиации, скорости ветра, температуре воздуха и пр. (мультимодальный вход);
- Усвоение особенностей данных - межгодовой изменчивости (индекс Арктической Осцилляции и пр.).

Команда проекта:

1. *Борисова Юлия* - руководитель проекта, разработка моделей.
2. *Кошкина Василиса* - тестирование моделей, анализ данных.